Report di Ricerca Accademica: Dinamiche Avanzate dei Mercati Finanziari e Asset Pricing

Executive Summary

L'architettura dei mercati finanziari e le metodologie di asset pricing hanno subito un profondo mutamento paradigmatico nel corso degli ultimi decenni. Questa evoluzione ha segnato il progressivo superamento dell'Ipotesi dei Mercati Efficienti (EMH) nella sua formulazione classica e dei modelli di pricing lineari, orientando l'indagine accademica verso un ecosistema complesso dominato da frizioni microstrutturali, asimmetrie informative, inefficienze comportamentali e, più recentemente, da architetture di apprendimento automatico ad alta dimensionalità. Il presente report fornisce una disamina esaustiva, oggettiva e rigorosa basata esclusivamente sulla letteratura scientifica peer-reviewed, su working paper istituzionali (NBER, FMI, Banche Centrali) e sulla ricerca quantitativa avanzata (Journal of Finance, Review of Financial Studies, ArXiv QuantFin).

In ottemperanza alle direttive di indagine, l'analisi integra prioritariamente i working paper pubblicati negli ultimi cinque anni, al fine di riflettere le attuali condizioni di mercato post-pandemia e il ritorno a regimi ad alta inflazione, tracciando cinque traiettorie fondamentali.

In primo luogo, la microstruttura dei mercati è stata irreversibilmente alterata dalla digitalizzazione e dal Trading ad Alta Frequenza (HFT). Sebbene la continuità degli scambi elettronici abbia ridotto i differenziali denaro-lettera (bid-ask spread) medi, la letteratura istituzionale dimostra che l'architettura a Limit Order Book (LOB) continuo incentiva una disfunzionale "corsa agli armamenti" tecnologica[1]. L'estrazione di rendite tramite arbitraggi di latenza penalizza la fornitura di liquidità istituzionale, stimolando la migrazione dei volumi verso i mercati opachi (*dark pools*) e ravvivando il dibattito su design di mercato alternativi, quali le aste periodiche frequenti[2].

In secondo luogo, l'ambito del trading algoritmico e delle anomalie di mercato ha vissuto la cosiddetta crisi del "Factor Zoo". La documentazione di centinaia di anomalie apparentemente profittevoli ha costretto la comunità econometrica a innalzare i requisiti di significatività statistica ($t > 3.0$) per arginare il fenomeno del *data mining* e delle false scoperte[4].

Contemporaneamente, l'asset pricing empirico ha validato l'efficacia del Machine Learning: i modelli non lineari, gestendo interazioni complesse tra decine di covariate, dimostrano una capacità predittiva out-of-sample del premio al rischio nettamente superiore alle regressioni lineari standard[6].

In terzo luogo, la Finanza Comportamentale ha consolidato il proprio statuto epistemologico, dimostrando che i limiti all'arbitraggio e le deviazioni sistematiche dalla razionalità neoclassica non costituiscono un rumore transitorio. Il *sentiment* aggregato degli investitori guida i rendimenti in modo persistente e asimmetrico, impattando primariamente i titoli di difficile valutazione e con elevati costi di arbitraggio[8]. Quarto, la diatriba storica tra analisi tecnica e

fondamentale ha trovato nuove sintesi quantitative. Da un lato, l'analisi dei dati di bilancio (come l'effetto *accruals* o le metriche aggregate di qualità) persiste come fonte di alfa robusto[10]; dall'altro, l'analisi tecnica tradizionale fallisce i moderni test di probabilità di overfitting[12], pur trovando nuova legittimazione empirica quando i suoi indicatori (trend e momentum) vengono utilizzati congiuntamente a variabili macroeconomiche per la previsione dell'Equity Risk Premium[13]. A ciò si affianca la rivoluzione dei Large Language Models (LLMs), ormai certificati nella letteratura come estrattori di sentiment capaci di anticipare i rendimenti[15].
Infine, le dinamiche macroeconomiche recenti hanno documentato la transizione verso un regime di mercato inedito post-2022. L'aumento strutturale dell'inflazione e la restrizione monetaria hanno invertito la storica correlazione negativa tra azioni e obbligazioni, invalidando i fondamenti dell'asset allocation tradizionale (es. il portafoglio 60/40) e richiedendo modelli dinamici *regime-switching*[17].

Analisi Tematica (Literature Review)

1. Microstruttura dei Mercati e Liquidità

L'indagine della microstruttura analizza le regole di negoziazione e il modo in cui esse trasformano gli ordini latenti in prezzi e allocazioni definitive[19]. La struttura fondamentale dei mercati contemporanei è il Limit Order Book (LOB) continuo a doppia asta. In questo ecosistema, il Trading ad Alta Frequenza (HFT) ha assunto un ruolo egemonico, arrivando a rappresentare oltre il 70% dei volumi azionari statunitensi[20].
High-Frequency Trading e Latency Arbitrage La narrativa iniziale sull'HFT, prevalentemente focalizzata sul restringimento dei bid-ask spread derivante dall'automazione del *market making*, è stata progressivamente sfidata da analisi empiriche più profonde[19]. Il paper seminale di Budish, Cramton e Shim (2015) dimostra che l'architettura a tempo continuo del LOB genera un'inefficienza intrinseca: una competizione per la priorità temporale che sfocia in un "latency arbitrage" (arbitraggio di latenza)[1]. In presenza di uno shock informativo, i trader più veloci riescono a "colpire" le quotazioni stantie dei market maker prima che questi ultimi riescano a cancellarle. L'evidenza basata su "message data" (che includono i tentativi di cancellazione falliti, a differenza dei tradizionali dataset TAQ) stima che tale arbitraggio costi ai mercati miliardi di dollari annualmente, funzionando come una tassa sulla fornitura di liquidità[21]. La ricerca di Budish et al. suggerisce che le *Frequent Batch Auctions* (aste periodiche a intervalli di millisecondi) eliminerebbero il vantaggio del microsecondo, ristabilendo l'equilibrio e migliorando il benessere complessivo del mercato[1]. Soluzioni intermedie, come l'introduzione di "speed bumps" asimmetrici (es. l'ordine M-ELO del Nasdaq), hanno mostrato nei working paper recenti una capacità di stabilizzare la volatilità intraday[20].
Tossicità del Flusso degli Ordini e Liquidità La modellazione della liquidità si avvale ampiamente del parametro *Kyle's Lambda* (λ), introdotto nel 1985 per quantificare l'impatto di mercato (*price impact*), ovvero la sensibilità del prezzo al flusso netto di ordini[23]. Un aumento del parametro lambda segnala che i market maker percepiscono il flusso in ingresso come "tossico", ossia dominato da trader informati (adverse selection), inducendoli a ritirare la liquidità e ad allargare gli spread[25]. La misurazione contemporanea dell'impatto di mercato, secondo le

teorizzazioni di Bouchaud, obbedisce a una "Square Root Law": l'impatto di prezzo non è lineare, ma cresce in proporzione alla radice quadrata del volume scambiato, indicando che la liquidità latente si addensa in prossimità del prezzo corrente e si dirada esponenzialmente agli estremi del LOB[27].

Dark Pools, PFOF e la Frammentazione dei Mercati Le difficoltà nell'eseguire grandi ordini istituzionali sui mercati regolamentati (lit markets) senza subire impatti di prezzo catastrofici hanno catalizzato l'uso delle *dark pools*[3]. La letteratura empirica rileva un effetto ambivalente: se l'introduzione di sedi di negoziazione opache incrementa il volume totale scambiato aggregato minimizzando l'impatto per gli istituzionali, una migrazione eccessiva dei volumi depaupera la *price discovery* nel mercato trasparente, ampliando gli spread per chi vi rimane[20]. Sul fronte retail, la struttura dei mercati è dominata dal *Payment for Order Flow* (PFOF). Nonostante il forte dibattito pubblico e normativo, studi accademici del 2023 (Schwarz et al., Ernst e Spatt) basati su dati proprietari e report Rule 605 documentano che il pagamento in sé (nell'ordine di frazioni di centesimo) non è il fattore primario che determina la qualità dell'esecuzione[29]. La vasta dispersione nei prezzi di esecuzione tra diversi broker deriva invece dalla "tossicità" del portafoglio clienti (order flow segmentation): i *wholesalers* internalizzano i flussi retail offrendo un miglioramento di prezzo (*price improvement*) maggiore a quei broker la cui base utenti dimostra minore sofisticazione (e quindi minor rischio di selezione avversa)[31].

2. Trading Algoritmico e Anomalie di Mercato

La ricerca sull'asset pricing empirico ha trascorso decenni identificando "anomalie" sistematiche che il Capital Asset Pricing Model (CAPM) non riusciva a spiegare. La pietra angolare moderna, il Modello a 5 Fattori di Fama-French (2015), ha dimostrato che gran parte del cross-section dei rendimenti azionari è spiegata dall'esposizione a cinque dimensioni di rischio: mercato, capitalizzazione (Size), rapporto Book-to-Market (Value), redditività (Profitability - RMW) e aggressività degli investimenti (Investment - CMA)[33].

Il Factor Zoo e la Crisi della Replicabilità La facilità di testare strategie quantitative su vasti dataset ha generato il fenomeno che Harvey, Liu e Zhu (2016) hanno battezzato il "Factor Zoo"[4]. Gli autori hanno censito oltre 316 fattori pubblicati sulle principali riviste accademiche, dimostrando che il tradizionale livello di significatività statistica ($t = 2.0$, corrispondente a $p = 0.05$) è gravemente insufficiente a causa del *multiple testing problem*[4]. Quando migliaia di regressioni vengono condotte sugli stessi dati storici, decine di strategie appaiono profittevoli per puro caso. Il nuovo standard accademico stabilisce che, per dichiarare valida una nuova anomalia, il test t-statistic debba essere innalzato ad almeno 3.0. Sotto questa lente, oltre la metà dei fattori storici perde significatività out-of-sample, suggerendo che molti premi documentati fossero artefatti di data mining[4].

Apprendimento Automatico e Previsione dei Rendimenti Per affrontare l'alta dimensionalità e l'intrinseca non-linearità dei mercati moderni, la ricerca ha spostato l'asse verso l'Apprendimento Automatico. Nello studio definitivo di Gu, Kelly e Xiu (2020) sulla *Review of Financial Studies*, gli autori applicano un vasto arsenale di modelli (Ordinary Least Squares, Partial Least Squares, Principal Component Analysis, Elastic Net, Random Forest, Gradient Boosting e Reti Neurali) all'asset pricing empirico[6]. I risultati dimostrano inequivocabilmente che

i metodi di machine learning sovraperformano i tradizionali approcci lineari. Le Reti Neurali (con strutture feed-forward a più strati) raggiungono i migliori risultati in termini di R-quadro predittivo out-of-sample, con un tasso di errore significativamente inferiore rispetto all'OLS[6]. La superiorità deriva dalla capacità degli algoritmi ad albero e delle reti neurali di catturare complesse interazioni tra fattori (es. l'interazione simultanea tra un calo di liquidità, uno shock di slancio e un segnale di valore) che sfuggono alla modellazione econometrica convenzionale[6]. I segnali che il machine learning identifica costantemente come più informativi sono invariabilmente legati a dinamiche di trend dei prezzi (momentum a breve termine e *reversal*), metriche di liquidità e volatilità passata[6]. *In termini di applicazioni pratiche, per la modellazione predittiva indicata dai paper istituzionali e da ArXiv QuantFin, la comunità quantitativa si appoggia primariamente al linguaggio Python, utilizzando librerie come TensorFlow e PyTorch. Le architetture maggiormente citate per le serie storiche finanziarie includono le reti LSTM (Long Short-Term Memory), capaci di mitigare il problema del gradiente evanescente e memorizzare dipendenze di mercato a lungo raggio, e, più recentemente, i Transformer con meccanismi di Attention*[6].

Reinforcement Learning nell'Esecuzione e Gestione del Portafoglio Una delle frontiere più esplorate nei working paper degli ultimi 5 anni è l'uso del Deep Reinforcement Learning (DRL) per la gestione di portafoglio e l'ottimizzazione dell'esecuzione. Abbandonando la necessità di prevedere puntualmente il prezzo futuro, il DRL (es. Deep Q-Networks e Proximal Policy Optimization) tratta il mercato come un ambiente stocastico in cui un agente massimizza una funzione di ricompensa (es. Indice di Sharpe o minimizzazione dell'impatto di mercato)[36]. Studi recenti documentano che agenti addestrati tramite DRL riescono a replicare e persino superare le strategie ottimali analitiche di tipo Almgren-Chriss, adattandosi dinamicamente all'asimmetria del LOB e alla volatilità intraday, rendendo superate le strategie statiche come la Volume Weighted Average Price (VWAP)[36].

3. Finanza Comportamentale (Behavioral Finance)

La Finanza Comportamentale, sintetizzata nell'epocale lavoro di Barberis e Thaler (2003), colma il divario tra il comportamento ideale degli *Homo Economicus* e la realtà empirica. Il framework si poggia su due pilastri interdipendenti: i limiti all'arbitraggio (frizioni istituzionali che impediscono alle forze razionali di ripristinare il valore fondamentale) e la psicologia cognitiva (bias sistematici nel processamento dell'informazione)[8].

Investor Sentiment e Inefficienze Asimmetriche Il fattore aggregante della disciplina è l'investor sentiment, formalizzato matematicamente da Baker e Wurgler (2006, 2007)[9]. Il loro indice ortogonalizzato isola le fluttuazioni macroeconomiche utilizzando proxy comportamentali come il differenziale tra i rendimenti sui dividendi, l'attività delle IPO (numero e rendimento del primo giorno), il turnover aggregato e lo sconto sui fondi chiusi[9]. I risultati accademici indicano che il sentiment non muove l'intero mercato in modo uniforme. Piuttosto, esiste una marcata asimmetria cross-sectional: durante i regimi di elevato ottimismo, l'eccesso di domanda irrazionale si concentra sui titoli "difficili da prezzare" e "difficili da arbitrare" (aziende a bassa capitalizzazione, start-up senza profitti, titoli con estrema volatilità e assenza di dividendi)[9]. Questi asset subiscono fortissime dislocazioni di prezzo poiché la correzione al ribasso è

ostacolata dai costi e dai vincoli normativi associati allo *short-selling*, che prevengono l'intervento immediato degli arbitraggisti istituzionali[9]. Di conseguenza, i rendimenti attesi di questi asset nei periodi successivi a picchi di sentiment risultano sistematicamente inferiori e spesso negativi, configurandosi come una delle anomalie predittive più robuste della finanza moderna[9]. A livello microscopico, la persistenza del bias di overconfidence (sopravvalutazione delle proprie informazioni) e il *disposition effect* (la tendenza a liquidare prematuramente le posizioni in guadagno trattenendo quelle in perdita) continuano a fornire liquidità involontaria alle strategie algoritmiche di mean-reversion[8].

4. Efficacia dell'Analisi Tecnica vs Fondamentale

La letteratura accademica offre prospettive sfaccettate e talvolta controintuitive sull'utilità dell'analisi tecnica e fondamentale per la previsione dei rendimenti.

L'Analisi Fondamentale Quantitativa: Accruals e F-Score I dati empirici confermano solidamente la capacità predittiva dell'analisi fondamentale quando applicata in modo quantitativo su ampi set di dati. Il paper di Sloan (1996) sull'anomalia degli *accruals* ha dimostrato che i prezzi di mercato non riflettono istantaneamente le diverse proprietà delle componenti degli utili[11]. Poiché la componente legata ai flussi di cassa operativi è molto più persistente nel tempo rispetto alla componente contabile (accruals), gli investitori tendono a "fissarsi" sul dato netto aggregato dell'utile, sovrastimando le performance future delle aziende con alti accruals e sottostimando quelle con forti cash flow. Questa asimmetria genera prevedibili ritorni anomali quando gli utili successivi vengono rilasciati e il mercato è forzato a correggere le proprie aspettative[11]. Parallelamente, Piotroski (2000) ha creato l'**F-Score**, un aggregato di nove segnali contabili binari che valutano la traiettoria della redditività (es. variazione del ROA), della leva finanziaria/liquidità e dell'efficienza operativa. L'applicazione rigorosa di questo filtro ai portafogli *Value* (società con alto Book-to-Market, storicamente inclini al *distress* finanziario) ha dimostrato di separare efficacemente le società destinate al fallimento dalle società sottovalutate destinate a un rimbalzo fondamentale, incrementando il rendimento annuale medio del portafoglio di 7.5% su un periodo di vent'anni[10].

L'Analisi Tecnica e la Crisi dell'Overfitting Le valutazioni storiche (es. la rassegna di Park e Irwin, 2007) mostravano una certa profittabilità dei pattern tecnici (es. *moving average crossover*, figure di *supporto/resistenza*) nei mercati fino agli anni '90[50]. Tuttavia, con la diffusione dell'efficienza algoritmica, l'evidenza empirica out-of-sample sulle regole di analisi tecnica isolata indica una sistematica distruzione di valore, incapace di compensare i costi di transazione e lo slittamento dei prezzi (*slippage*)[50]. La comunità quantitativa ha affrontato il problema con la matematica del **Probability of Backtest Overfitting (PBO)**, formalizzata da Lopez de Prado e Bailey (2014)[12]. Il teorema dimostra che esplorare e ottimizzare decine di configurazioni dei parametri di un indicatore tecnico su una serie storica garantisce artificialmente l'identificazione di un apparente In-Sample Sharpe Ratio eccellente, che si traduce ineluttabilmente in fallimento Out-of-Sample. Applicando la *Combinatorially Symmetric Cross-Validation* (CSCV), il PBO misura matematicamente il rischio di sovra-ottimizzazione, relegando la gran parte dell'analisi tecnica retail al rango di artefatto statistico[12]. Nonostante ciò, studi recenti pubblicati su *Management Science* (Neely et al. 2014) e sui working paper odierni

rivalutano gli indicatori tecnici (come filtri di trend a bassa frequenza) quando combinati *ortogonalmente* con variabili macroeconomiche. In questo setting predittivo istituzionale, l'analisi tecnica aggiunge notevole valore economico nel prevenire grandi *drawdown* dell'Equity Risk Premium[13].

La Frontiera dei Large Language Models (LLMs) I working paper più influenti emersi tra il 2024 e il 2025 su *ArXiv QuantFin* esplorano l'efficacia dei Modelli Linguistici di Grandi Dimensioni per sintetizzare l'analisi fondamentale[15]. Architetture specializzate come *FinBERT* o *FinGPT* processano in pochi millisecondi trasmissioni di bilancio, documentazione SEC e rassegne stampa, estraendo *score* di sentiment finanziario ad altissima dimensionalità. La letteratura dimostra associazioni statisticamente significative tra i punteggi assegnati dai LLM e l'eccesso di rendimento direzionale nei giorni di contrattazione immediatamente successivi (specialmente in contesti di asimmetria informativa), segnando il definitivo connubio tra elaborazione semantica e analisi quantitativa pura[16].

5. Dinamiche Macroeconomiche e Asset Allocation

Fino al 2021, la costruzione di portafogli istituzionali globali, come le allocazioni 60/40 o i framework *Risk Parity*, si è retta sul pilastro della correlazione negativa tra le asset class azionarie e le obbligazioni governative, operante in un regime di inflazione secolare decrescente o stabile.

Inflazione e Cambio di Regime (Regime Shift) I paper economici e i report delle banche centrali post-2022 identificano uno shock strutturale nelle dinamiche macroeconomiche. Il ritorno a pressioni inflazionistiche endogene ed esogene ha forzato le banche centrali a un irrigidimento quantitativo (QT) rapido[17]. Questo ha causato la ri-prezzatura istantanea del tasso di sconto di base, provocando crolli simultanei in tutte le classi di attivi a lunga *duration*. In regimi ad alta inflazione (superiore alla media mobile storica), la covarianza tra azioni e obbligazioni si inverte, assumendo valori positivi persistenti[17]. Sotto questo nuovo regime, le obbligazioni cessano di agire come stabilizzatori di volatilità e coperture (*hedge*) naturali contro le fluttuazioni azionarie, esponendo le architetture di Markowitz a *drawdown* superiori rispetto alle previsioni storiche In-Sample. Pertanto, l'implementazione pratica del portafoglio post-pandemia impone lo sviluppo di architetture di *Regime-Switching* dinamiche, la stima tempestiva dell'output gap e dell'inflazione attesa, e l'integrazione strutturale di asset tangibili o premi al rischio di volatilità per ricalibrare le efficient frontiers.

Modelli e Metriche Chiave

La moderna indagine accademica poggia su un solido corpus econometrico. Di seguito sono elencati i modelli e le metriche sistematicamente richiamati per la ricerca quantitativa e la formulazione delle politiche di trading.

Modello / Metrica	Equazione / Base Matematica	Applicazione e Rilevanza Accademica
GARCH (Generalized	$\sigma_t^2 = \omega + \sum_{i-1}^{q} \alpha_i \epsilon_{t-i}^2 +$	Introdotto da Tim Bollerslev

Autoregressive Conditional Heteroskedasticity)		(1986), è il gold standard per modellare la volatilità stocastica (eteroschedasticità) nei log-rendimenti, essenziale per il pricing delle opzioni e le stime di Value-at-Risk[57].
Regressione Two-Pass di Fama-MacBeth	1. $R_{i,t} = \alpha_i + \beta_i R_{M,t} + \epsilon_{i,t}$ 2. $R_{i,t} = \gamma_{0,t} + \gamma_{1,t}\hat{\beta}_i + u_{i,t}$	Sviluppata nel 1973 per testare il CAPM e i modelli multifattoriali, previene distorsioni da cross-correlazione tra residui nei panel data finanziari. Recenti estensioni (Bai e Zhou, 2015) correggono i bias sui piccoli campioni[58].
Almgren-Chriss Optimal Execution	$\min_x (E[C(x)] + \lambda Var($	Il framework matematico definitivo (2000) per la liquidazione di grandi ordini istituzionali, bilanciando linearmente il costo dell'impatto di mercato ($E[C]$) e il rischio di prezzo ($Var(C)$) in funzione dell'avversione al rischio λ [61].
Avellaneda-Stoikov Market Making	$r(q,t) = s - q\gamma\sigma^2(T -$ (Prezzo di riserva)	Modello di controllo stocastico (inventario asimmetrico) utilizzato dagli HFT per stabilire dinamicamente lo spread (bid/ask) all'interno di un LOB per minimizzare il rischio di inventario in un orizzonte continuo[63].

Kyle's Lambda (λ)	$\Delta P = \lambda Q + \epsilon$	Misura storica (1985) della tossicità dell'Order Flow. La pendenza della retta di regressione stima quanto ogni singola unità di volume (Q) scambiata sposti permanentemente il prezzo (P) a causa di trader informati[23].
Probability of Backtest Overfitting (PBO)	$PBO = P(SBO < 0) =$	Algoritmo basato sulla *Combinatorially Symmetric Cross-Validation* (CSCV) di Lopez de Prado et al. (2014) per stimare il tasso matematico di decadimento out-of-sample (SBO) di una strategia[12].
Hamilton Regime-Switching Model	Modello di transizione markoviana non osservabile $S_t \in \{1, 2, \dots, K\}$	Modello econometrico (1989) fondamentale per catturare i cambi strutturali nelle distribuzioni finanziarie (es. da bassa ad alta inflazione, o da mercati *bull* a recessioni) per l'asset allocation dinamica[18].

Mappa delle Fonti

Per una prosecuzione dell'indagine a livello istituzionale e una corretta implementazione metodologica, si raccomanda la lettura obbligatoria e la sintesi computazionale dei seguenti paper, suddivisi per importanza storica e rilevanza contemporanea (ultimi 5 anni).

Paper Storici e Fondamentali dell'Ecosistema Quantitativo:

- **Fama, E.F., & MacBeth, J.D. (1973).** *"Risk, Return, and Equilibrium: Empirical Tests"*, Journal of Political Economy. L'origine della metrica di cross-sectional regression, imprescindibile per validare qualsiasi anomalia o rischio sistematico[58].
- **Kyle, A.S. (1985).** *"Continuous Auctions and Insider Trading"*, Econometrica. Definisce la grammatica del market impact istituzionale (Kyle's Lambda) in presenza di asimmetria informativa[24].
- **Sloan, R.G. (1996).** *"Do Stock Prices Fully Reflect Information in Accruals and Cash Flows about Future Earnings?"*, The Accounting Review. Evidenza seminale della

fissazione miope degli investitori sulle variabili contabili (Accrual Anomaly)[11].

- **Piotroski, J.D. (2000).** *"Value Investing: The Use of Historical Financial Statement Information to Separate Winners from Losers"*, Journal of Accounting Research. La validazione statistica dei segnali di qualità aziendale tramite F-Score[49].
- **Almgren, R., & Chriss, N. (2000).** *"Optimal Execution of Portfolio Transactions"*, Journal of Risk. Il testo sacro per gli algoritmi di esecuzione ottima (TWAP/VWAP istituzionale) sui mercati digitali[61].
- **Barberis, N., & Thaler, R. (2003).** *"A Survey of Behavioral Finance"*, Handbook of the Economics of Finance. La struttura architettonica per integrare razionalità limitata, limits to arbitrage e preferenze eterodosse nei modelli finanziari[8].
- **Baker, M., & Wurgler, J. (2006).** *"Investor Sentiment and the Cross-Section of Stock Returns"*, Journal of Finance. L'indice accademico predittivo più noto sulle derive comportamentali trasversali[9].
- **Budish, E., Cramton, P., & Shim, J. (2015).** *"The High-Frequency Trading Arms Race: Frequent Batch Auctions as a Market Design Response"*, Quarterly Journal of Economics. Espone il costo occulto dell'arbitraggio di latenza nei LOB continui a discapito della liquidità reale[1].
- **Fama, E.F., & French, K.R. (2015).** *"A Five-Factor Asset Pricing Model"*, Journal of Financial Economics. Ampliamento del modello storico per includere gli investimenti e la robustezza reddituale[33].
- **Harvey, C.R., Liu, Y., & Zhu, H. (2016).** *"...and the Cross-Section of Expected Returns"*, Review of Financial Studies. Definisce le nuove soglie dell'economia quantitativa per abbattere le false scoperte e il factor zoo[4].

Working Paper e Ricerca Recente (Contesto Post-Pandemia e HFT Avanzato):

- **Gu, S., Kelly, B., & Xiu, D. (2020).** *"Empirical Asset Pricing via Machine Learning"*, Review of Financial Studies. Test definitivo sull'utilità pratica delle architetture ad albero e neurali nel superare l'econometria lineare per il risk premium prediction[6].
- **Schwarz, C., Barber, B., Huang, X., Jorion, P., & Odean, T. (2023).** *"The 'Actual Retail Price' of Equity Trades"*, Journal of Finance (SSRN Working Papers). Esplosione del mito del PFOF puro, dimostrando tramite dati Rule 605 il ruolo cardinale della tossicità del flusso ordini broker-by-broker[30].
- **Varie Pubblicazioni su ArXiv QuantFin e NBER (2023-2026).** Tra i quali spiccano gli studi sul Reinforcement Learning adattivo nei processi di esecuzione ottima e l'applicazione massiva dei Large Language Models (es. modelli FinBERT e FinGPT) come analisti informazionali in grado di assorbire l'alpha dalle narrative finanziarie a velocità non umane[15].

Bibliografia

1. Academic Papers | TernQED, https://ternqed.com/resources/papers/
2. Frequent batch auctions and informed trading - EconStor, https://www.econstor.eu/bitstream/10419/251785/1/1796802263.pdf

3. Dark Pool Trading Strategies - WORKING PAPER SERIES, https://igier.unibocconi.eu/sites/default/files/media/publication/421.pdf
4. Harvey, Liu & Zhu (2016): ...and the Cross-Section of Expected, https://foxholm.com/q/research/harvey-liu-zhu-cross-section/
5. (PDF) The Evolution of Predictive Analytics: Machine Learning and, https://www.researchgate.net/publication/417221915_The_Evolution_of_Predictive_Analytics_Machine_Learning_and_the_Predictive_Step_in_Empirical_Asset_Pricing-From_Factor_Zoo_to_Factor_Refinery
6. Empirical Asset Pricing via Machine Learning Shihao Gu ... - NBER, https://www.nber.org/system/files/working_papers/w25398/revisions/w25398.rev1.pdf
7. Empirical Asset Pricing via Machine Learning: The Global Edition, https://www.iimb.ac.in/sites/default/files/inline-files/Empirical%20Asset-Pricing-Machine-Learning.pdf
8. (PDF) Behavioralizing Finance - ResearchGate, https://www.researchgate.net/publication/228204134_Behavioralizing_Finance
9. Aggregate investor sentiment and stock return synchronicity, https://ira.lib.polyu.edu.hk/bitstream/10397/89940/1/Chue_Aggregate_Investor_Sentiment.pdf
10. Piotroski's F Score-Value Investing | PDF - Scribd, https://www.scribd.com/document/995770214/8-Piotroski-s-F-Score-Value-Investing
11. Do Stock Prices Fully Reflect Information in Accruals and Cash, https://www.cuhk.edu.hk/acy2/workshop/June2009Wasley/1996TAR).pdf
12. Probability of backtest overfitting: Bailey method - Backtrex, https://backtrex.com/en/blog/probability-of-backtest-overfitting-bailey
13. Equity Premium Prediction: Are Economic and Technical Indicators, https://www.kielinstitut.de/fileadmin/Dateiverwaltung/IfW-Publications/fis-import/bdff722a-251e-4abb-bafc-7846f250ebd2-kwp-1987.pdf
14. The equity risk premium: a review of models - IDEAS/RePEc, https://ideas.repec.org/a/fip/fednep/00027.html
15. Agentic AI Nowcasting Predicts Stock Returns - arXiv, https://arxiv.org/html/2601.11958v1
16. [2412.19245] Sentiment trading with large language models - arXiv, https://arxiv.org/abs/2412.19245
17. Empirical Evidence on the Stock–Bond Correlation - Taylor & Francis, https://www.tandfonline.com/doi/full/10.1080/0015198X.2024.2317333
18. Google Sports Data, https://support.google.com/knowledgepanel/answer/9787176
19. (PDF) Evolution of Market Microstructure in the Age of AI From, https://www.researchgate.net/publication/414912034_Evolution_of_Market_Microstructure_in_the_Age_of_AI_From_Double-Sided_Continuous_Auctions_to_Agentic_Markets
20. DISSERTATION Market Microstructure and Financial Markets Stability, https://orbilu.uni.lu/bitstream/10993/52222/1/thesis.pdf
21. Quantifying the high-frequency trading "arms race" - the BIS,

https://www.bis.org/publications/working-paper-955-quantifying-high-frequency-trading-arms-race.pdf
22. Quantifying the High-Frequency Trading "Arms Race" - NBER, https://www.nber.org/system/files/working_papers/w29011/w29011.pdf
23. Understanding Order Flow Toxicity | by Simone Menaldo - Medium, https://medium.com/@simomenaldo/understanding-order-flow-toxicity-58fa317b3d01
24. Kyle's Lambda: Price Impact and the Cost of Informed Trading, https://microalphas.com/kyles-lambda/
25. A Microstructure and Liquidity-Focused High-Frequency Analys, https://matheo.uliege.be/bitstream/2268.2/24030/4/Master_Thesis_final_Geudens_Nathan.pdf
26. detection and prevention of market manipulation and insider trading, https://scholarexpress.net/index.php/wefb/article/download/5833/4930/10783
27. Markets never forget: the lasting impression of square-root impact, https://www.risk.net/cutting-edge/views/7963090/markets-never-forget-the-lasting-impression-of-square-root-impact
28. Dark Pool Trading Strategies, Market Quality and Welfare, https://www.researchgate.net/publication/295398580_Dark_Pool_Trading_Strategies_Market_Quality_and_Welfare
29. Payment for Order Flow and the Retail Trading Experience, https://wffi.wharton.upenn.edu/wp-content/uploads/2023/10/Payment-for-Order-Flow.pdf
30. Retail Execution Quality Analysis | PDF | Market (Economics) - Scribd, https://www.scribd.com/document/974465819/The-Retail-Execution-Quality-Landscape-2025-Journal-of-Financial-Economics
31. Who Is Minding the Store? Order Routing and Competition in Retail, https://www.sec.gov/comments/s7-29-22/s72922-310545-808062.pdf
32. Payment for Order Flow Is Not Why Your Trade Costs More | ProfitOwl, https://profit-owl.com/blog/payment-for-order-flow-best-execution
33. testing fama-french five-factor asset pricing model with - arno, http://arno.uvt.nl/show.cgi?fid=150225
34. FAMA-FRENCH FIVE FACTOR MODEL AND THE NECESSITY 0F, https://dergipark.org.tr/en/pub/pap/article/506084
35. Agentic Empirical Asset Pricing:Methodological Foundations - arXiv, https://arxiv.org/html/2609.00731v1
36. arXiv:2307.10649v1 [q-fin.CP] 20 Jul 2023, https://arxiv.org/pdf/2307.10649
37. arXiv:2311.05743v1 [q-fin.CP] 9 Nov 2023, https://arxiv.org/pdf/2311.05743
38. Deep Reinforcement Learning for Portfolio Optimization using Latent, https://arxiv.org/pdf/2102.06233
39. arXiv:2003.06497v1 [q-fin.MF] 13 Mar 2020, https://www.cfm.com/wp-content/uploads/2022/12/123-Deep-deterministic-portfolio-optimisation.pdf
40. An Adaptive Dual-level Reinforcement Learning Approach for ... - arXiv, https://arxiv.org/html/2307.10649v1

41. Chapter 18 A survey of behavioral finance - Semantic Scholar, https://www.semanticscholar.org/paper/Chapter-18-A-survey-of-behavioral-finance-Barberis-Thaler/d74dbb125a70866f9fdd78449eb4402db6f7db01
42. An enhanced investor sentiment index - Taylor & Francis, https://www.tandfonline.com/doi/full/10.1080/1351847X.2023.2247440
43. Investor Sentiment Aligned: A Powerful Predictor of Stock Returns, https://www.uts.edu.au/globalassets/sites/default/files/FDG_Seminar_140730.pdf
44. News sentiment indicators and the cross-section of stock returns in, https://iris.unimore.it/retrieve/handle/11380/1386248/918698/2025.%20Gambarelli%20and%20Muzzioli%20News%20sentiment%20indicators.pdf
45. Investor Sentiment in the Stock Market | Request PDF - ResearchGate, https://www.researchgate.net/publication/407245321_Investor_Sentiment_in_the_Stock_Market
46. The use of behavioral finance in the wealth management process, https://www.econstor.eu/bitstream/10419/66764/1/68885026X.pdf
47. Do Stock Prices Fully Reflect Information in Accruals and Cash flows, https://scispace.com/papers/do-stock-prices-fully-reflect-information-in-accruals-and-26qpsaucw9
48. Do share prices fully reflect the information about future earnings in, https://www.econstor.eu/bitstream/10419/218215/1/sajbm-v30i4-0763.pdf
49. Value Investing: The Use of Historical Financial Statement ... - Free, http://lemeunier.gilbert.free.fr/Investissement/DOCS/PDF/Piotroski.pdf
50. The Profitability of Technical Analysis: A Review by Cheol-Ho Park, https://farmdoc.illinois.edu/assets/marketing/agmas/AgMAS04_04.pdf
51. What do we know about profitability of technical analysis, https://www.researchgate.net/publication/4765054_What_do_we_know_about_profitability_of_technical_analysis
52. pypbo - Probability of Backtest Overfitting in Python - GitHub, https://github.com/esvhd/pypbo
53. Impact of LLMs news Sentiment Analysis on Stock Price Movement, https://arxiv.org/pdf/2602.00086
54. FinSMART: Financial Sentiment Analysis for Algorithmic Trading, https://arxiv.org/html/2607.28127v1
55. A Survey of Large Language Models in Financial Prediction and, https://arxiv.org/html/2510.05533v1
56. Macroeconomic News and Stock–Bond Comovement*, http://www.econ2.jhu.edu/people/duffee/rfac066.pdf
57. Generalized autoregressive conditional heteroskedasticity, https://ideas.repec.org/a/eee/econom/v31y1986i3p307-327.html
58. Fama–MacBeth regression - Wikipedia, https://en.wikipedia.org/wiki/Fama%E2%80%93MacBeth_regression
59. Fama–MacBeth two-pass regressions: Improving risk premia estimates, https://ideas.repec.org/a/eee/finlet/v15y2015icp31-40.html
60. Fama-MacBeth Regression | Finance Toolkit - Jeroen Bouma, https://www.jeroenbouma.com/projects/financetoolkit/docs/econometrics/fama-ma

cbeth-regression
61. joshuapjacob/almgren-chriss-optimal-execution - GitHub, https://github.com/joshuapjacob/almgren-chriss-optimal-execution
62. Optimal Execution of Portfolio Transactions*, https://www.smallake.kr/wp-content/uploads/2016/03/optliq.pdf
63. Avellaneda-Stoikov for AMMs - Medium, https://medium.com/@ioanaroceanu/avellaneda-stoikov-for-amms-cbe8246b6893
64. Guide to the Avellaneda & Stoikov Strategy - Hummingbot, https://hummingbot.org/blog/guide-to-the-avellaneda--stoikov-strategy/
65. THE PROBABILITY OF BACKTEST OVERFITTING - David H Bailey, https://www.davidhbailey.com/dhbpapers/backtest-prob.pdf
66. Flow Toxicity and Liquidity in a High Frequency World - ResearchGate, https://www.researchgate.net/publication/228261180_Flow_Toxicity_and_Liquidity_in_a_High_Frequency_World
67. Value investing: The use of historical financial statement i, https://ideas.repec.org/a/bla/joares/v38y2000ip1-41.html
68. はじめに - 日本証券経済研究所, https://www.jsri.or.jp/publish/review/pdf/64ex/02_siryo.pdf
69. Empirical Asset Pricing via Machine Learning - IDEAS/RePEc, https://ideas.repec.org/a/oup/rfinst/v33y2020i5p2223-2273..html